Reporte: Q-Learning en Cliff Walking.

- ¿Por qué el camino de 13 pasos, pegado al alcantilado, es optimo?

  Porque es la ruta mas corta entre el inicio y la meta. Cada paso resta -1, asi que ir pegado al borde toma justo 13 movimientos (-13). Si se rodea por arriba por arriba para no arriesgarse, se dan mas pasos y se pierden mas puntos.

- ¿Por qué la curva de entrenamiento queda por debajo de -13 aunque la politica greedy ya sea optima?

  Por la exploración. Aunque el agente ya conozca la ruta ideal, el 10% de las veces se mueve al azar. Como va junto al abismo, cualquier error lo tira y le pone el castigo -100, bajando el promedio. Si se evalua con $\varepsilon = 0$ ya no explora y saca el -13.

- En el paso que cae al alcantilado, ¿Cual es s' en el backup de Q-learning, y porque ese backup no trata el alcantilado como estado terminal?

  El estado siguiente s' es la casilla S. No es terminal porque caerse no termina el juego, solo te penaliza y te regresa al punto de partida para seguir intentando.